

## UNIDAD 8

# Metodología de ML en blockchain

Datos de Bitcoin y Ethereum, validación temporal y evidencia reproducible

# Mercado, actividad y estructura

| Dimensión                 | Observación                                 | Pregunta de análisis                           |
|---------------------------|---------------------------------------------|------------------------------------------------|
| <b>Mercado</b>            | Precios, retornos, volumen y liquidez       | ¿Qué información mejora una estimación futura? |
| <b>Actividad on-chain</b> | Transacciones, fees, gas y uso de contratos | ¿Cómo cambia la utilización de la red?         |
| <b>Estructura</b>         | Conexiones entre transacciones o cuentas    | ¿Qué aporta el vecindario de un nodo?          |

# Formulación del experimento

## Unidad de observación

Definir si cada fila es un día, una transacción, una dirección o un snapshot de grafo.

## Momento de decisión

Fijar qué información está disponible cuando se calcula la predicción.

## Comparación

Precisar objetivo, horizonte, baseline y métrica antes de seleccionar una arquitectura.

# Variables objetivo

$$r_t = \ln(P_t / P_{t-1})$$

$$d_{t+1} = \mathbf{1}[r_{t+1} > 0]$$

## Regresión y clasificación

El retorno es un valor continuo. La dirección necesita definir qué ocurre con los retornos iguales a cero o cercanos a cero.

## Volatilidad y régimen

El riesgo y el estado del mercado requieren definiciones operativas diferentes del precio.

# Un objetivo de varianza realizada

$$v_{t,H} = (1/H) \sum_{j=1}^H r_{t+j}^2$$

$$\sigma_{t,H} = \sqrt{v_{t,H}}$$

## Definición del ejemplo

Varianza realizada media sobre los próximos  $H$  retornos, usando una aproximación de media cero.

## Disponibilidad de la etiqueta

El objetivo asociado al instante  $t$  se conoce recién al completar el horizonte  $H$ .

# Variables de Bitcoin y Ethereum

| Familia          | Bitcoin                                          | Ethereum                                                  |
|------------------|--------------------------------------------------|-----------------------------------------------------------|
| <b>Mercado</b>   | OHLCV, spread y liquidez                         | OHLCV, liquidez CEX y DEX                                 |
| <b>Red</b>       | Fees, UTXO, dificultad y hash rate estimado      | Gas, base fee, burn y staking                             |
| <b>Actividad</b> | Transacciones y direcciones activas              | Transferencias, contratos y actividad de L2               |
| <b>Medición</b>  | Dirección, UTXO y entidad son unidades distintas | Cuenta, contrato, evento y llamada son unidades distintas |

# Calidad y disponibilidad del dato

## Tiempo de evento y de publicación

Guardar cuándo ocurrió un evento y cuándo la fuente permitió observarlo. Las revisiones posteriores requieren seguimiento.

## Cobertura y consistencia

Documentar mercado, moneda de cotización, zona horaria, frecuencia, faltantes y duplicados.

## Agregaciones causales

Calcular ventanas hasta el instante de decisión.  
Registrar retrasos, confirmaciones y criterios de cierre.

# Pipeline del experimento

| Etapa       | Producto                      | Control                               |
|-------------|-------------------------------|---------------------------------------|
| Ingesta     | Datos originales y metadatos  | Fuente, fecha, esquema y hash         |
| Preparación | Características y objetivos   | Disponibilidad, faltantes y unidades  |
| Validación  | Folds temporales              | Horizonte y maduración de etiquetas   |
| Modelado    | Predicciones fuera de muestra | Mismos datos y presupuesto comparable |
| Resultados  | Métricas y errores            | Trazabilidad hasta cada observación   |

# Baselines según la tarea

| Modelo                   | Pregunta que permite contrastar              | Condición de comparación                |
|--------------------------|----------------------------------------------|-----------------------------------------|
| <b>Naive o constante</b> | ¿Se supera una referencia mínima?            | Precio previo, retorno cero o tasa base |
| <b>ARIMA</b>             | ¿Existe estructura temporal lineal?          | Mismo objetivo y horizonte              |
| <b>GARCH</b>             | ¿Persiste la varianza condicional?           | Target y escala de riesgo compatibles   |
| <b>RF o XGBoost</b>      | ¿Aportan relaciones tabulares no lineales?   | Mismas variables y folds                |
| <b>LSTM, GRU o GNN</b>   | ¿Aporta la estructura temporal o relacional? | Ablación, costo y estabilidad           |

# Validación walk-forward

| Fold               | Entrenamiento                       | Validación y prueba           |
|--------------------|-------------------------------------|-------------------------------|
| 1                  | Período inicial                     | Bloque posterior              |
| 2                  | Período inicial ampliado            | Siguiente bloque posterior    |
| 3                  | Período inicial ampliado nuevamente | Nuevo bloque posterior        |
| <b>Alternativa</b> | Ventana móvil de tamaño fijo        | Bloque posterior a la ventana |

# Horizontes superpuestos y purga

**Etiqueta del ejemplo t: retornos de  $t+1$  a  $t+H$**

**Condición de entrenamiento al corte c:  $t + H \leq c$**

## Frontera temporal

Una fila anterior al corte puede tener un objetivo que usa información posterior al corte.

## Control

Purgar ejemplos con etiquetas aún no observadas y definir el gap según horizonte y disponibilidad.

# Fuga de información

## Transformaciones

Ajustar scaler, imputación, selección de variables o embeddings con todo el período introduce información del test.

## Construcción del objetivo

Desplazar mal el target, usar una ventana centrada o unir una publicación futura contamina el experimento.

## Selección del modelo

Elegir hiperparámetros o reglas después de mirar el test convierte la prueba en parte del ajuste.

# Métricas y unidades

| Tarea         | Métrica                        | Lectura                                                          |
|---------------|--------------------------------|------------------------------------------------------------------|
| Regresión     | MAE y RMSE                     | Magnitud del error en unidades del objetivo                      |
| Dirección     | Acierto de signo               | Comparación con tasa base y banda neutral                        |
| Varianza      | QLIKE                          | $y/\hat{y} - \ln(y/\hat{y}) - 1$ , con $y$ y $\hat{y}$ positivos |
| Clasificación | Precision, recall, F1 y PR-AUC | Desempeño de la clase relevante y umbral                         |
| Estrategia    | Sharpe y drawdown              | Riesgo y costos bajo supuestos explícitos                        |

# Reproducibilidad y análisis de errores

## Registro del experimento

Versiones, semillas, fechas de corte, configuración y checksum del dato.

## Resultados verificables

Predicciones con fecha, valor observado, modelo y fold. Métricas por período y por objetivo.

## Interpretación

Comparar errores en episodios de estrés, congestión o cambios de régimen y reportar la variabilidad.

# Actividad metodológica BTC/ETH

## Diseño

Definir un objetivo de volatilidad diaria y seleccionar variables de mercado y on-chain disponibles al cierre.

## Experimento

Comparar una referencia de riesgo con un modelo tabular y una red temporal mediante los mismos folds.

## Defensa

Justificar horizonte, retrasos, métricas, familias de variables y límites de generalización.

# Bibliografía y documentación

## **scikit-learn. TimeSeriesSplit**

[https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.TimeSeriesSplit.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html)

## **scikit-learn. Common pitfalls and recommended practices**

[https://scikit-learn.org/stable/common\\_pitfalls.html](https://scikit-learn.org/stable/common_pitfalls.html)

## **Moiz y Raza (2026). Deep learning and GARCH family models**

<https://mf-journal.com/article/view/370>

## **Weber et al. (2019). Anti-Money Laundering in Bitcoin**

<https://arxiv.org/abs/1908.02591>

## **Lundberg y Lee (2017). A Unified Approach to Interpreting Model Predictions**

<https://arxiv.org/abs/1705.07874>