

UNIDAD 8

LSTM y GRU para BTC/ETH

Memoria temporal, construcción de ventanas y evaluación fuera de muestra

Secuencia de entrada y horizonte

$X[t] = [x[t-L+1], \dots, x[t]]$ objetivo: $y[t+H]$

Lote de entrada: $B \times L \times F$

L, H y F

L es la longitud de la ventana. H es el horizonte. F es el número de características por instante.

B y causalidad

B es la cantidad de ejemplos del lote. Cada ventana termina en el momento de decisión.

Ejemplo de ventana causal

Instante	Variables observadas	Uso
t-2	Retorno, volumen y gas	Primer paso de la ventana
t-1	Retorno, volumen y gas	Segundo paso de la ventana
t	Retorno, volumen y gas	Último paso disponible
t+1	Retorno futuro	Etiqueta del ejemplo, disponible después

MLP y recurrencia

Aspecto	MLP con retardos	RNN o LSTM
Representación	Ventana aplanada como vector	Secuencia de vectores
Información temporal	Orden codificado en las columnas	Estado actualizado en cada paso
Parámetros	Dependientes del tamaño de la entrada	Compartidos entre pasos temporales
Comparación	Baseline temporal válido	Aporte de recurrencia por demostrar

RNN y gradientes temporales

$$\mathbf{h}_t = \tanh(\mathbf{W}\mathbf{x}_t + \mathbf{U}\mathbf{h}_{t-1} + \mathbf{b})$$

Estado recurrente

$\mathbf{h}_t$ resume información de la secuencia procesada mediante parámetros compartidos.

Entrenamiento

La retropropagación en el tiempo puede producir gradientes que disminuyen o crecen mucho.

Controles

Las compuertas de LSTM y GRU, el clipping y la longitud de secuencia modifican el comportamiento.

LSTM: compuertas y candidato

$$\mathbf{q}_t = [\mathbf{h}_{t-1}, \mathbf{x}_t]$$

$$\mathbf{f}_t = \text{sigmoid}(\mathbf{W}_f \mathbf{q}_t + \mathbf{b}_f) \quad \mathbf{i}_t = \text{sigmoid}(\mathbf{W}_i \mathbf{q}_t + \mathbf{b}_i)$$

$$\mathbf{g}_t = \tanh(\mathbf{W}_g \mathbf{q}_t + \mathbf{b}_g) \quad \mathbf{o}_t = \text{sigmoid}(\mathbf{W}_o \mathbf{q}_t + \mathbf{b}_o)$$

f, i y o

Son las compuertas de olvido, entrada y salida.
Toman valores entre 0 y 1.

Candidato g

Propone nueva información para el estado de celda. Su rango es de -1 a 1.

LSTM: estado de celda y salida

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \mathbf{g}_t$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t)$$

Estado de celda $\mathbf{c}$

Combina memoria previa y nueva información. Se transmite al siguiente paso.

Estado oculto $\mathbf{h}$

Es la salida recurrente controlada por $\mathbf{o}$. Se utiliza en el siguiente paso y en la predicción.

Símbolo $\odot$

Indica multiplicación elemento a elemento, diferente del producto matricial.

Ejemplo numérico de memoria LSTM

$$c \text{ anterior} = 0,6 \quad f = 0,8 \quad i = 0,25 \quad g = -0,4$$

$$c \text{ nuevo} = 0,8 \times 0,6 + 0,25 \times (-0,4) = 0,38$$

$$o = 0,7 \quad h \text{ nuevo} = 0,7 \times \tanh(0,38) \approx 0,254$$

Lectura

La celda conserva 0,48 de la memoria y añade -0,10 de información candidata.

Alcance

Un componente escalar ilustrativo. Las compuertas se aprenden durante el entrenamiento.

GRU: reinicio y actualización

$$\mathbf{r}_t = \text{sigmoid}(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r)$$

$$\mathbf{z}_t = \text{sigmoid}(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z)$$

$$\mathbf{n}_t = \tanh(\mathbf{W}_n \mathbf{x}_t + \mathbf{b}_n + \mathbf{r}_t \odot (\mathbf{U}_n \mathbf{h}_{t-1} + \mathbf{b}_{hn}))$$

$$\mathbf{h}_t = (\mathbf{1} - \mathbf{z}_t) \odot \mathbf{n}_t + \mathbf{z}_t \odot \mathbf{h}_{t-1}$$

Convención utilizada

La notación sigue la ubicación del reset y de los sesgos del candidato en PyTorch.

Memoria

GRU mantiene un estado recurrente y no un estado de celda separado como LSTM.

LSTM, GRU y Transformer

Arquitectura	Mecanismo	Aspecto a evaluar
LSTM	Celda y tres compuertas	Capacidad temporal y costo de estados
GRU	Dos compuertas y un estado	Compacidad con igual hidden size
Transformer	Atención entre posiciones	Máscara causal, contexto y costo
Todas	Patrones aprendidos del dato	Resultados fuera de muestra y estabilidad

Familias de variables y ablación

Univariado

Retorno, precio o una medida de actividad. Permite construir una referencia sencilla.

Mercado y red

Agregar volumen, volatilidad y variables on-chain con disponibilidad documentada.

Valor incremental

Retirar cada familia por separado y comparar los mismos períodos, modelos y métricas.

Cuatro tareas temporales

Objetivo	Salida	Control principal
Retorno	Valor real	Unidades y baseline de retorno
Dirección	Probabilidad de subida	Calibración, tasa base y umbral
Volatilidad	Varianza o volatilidad positiva	Horizonte y target realizados
Régimen	Probabilidad por estado	Reglas de etiqueta y disponibilidad

Preprocesamiento por fold

Ajuste

Estimar scaler, imputación y selección de variables con entrenamiento.

Transformación

Aplicar esas transformaciones congeladas a validación y prueba.

Ventanas

Construir ejemplos según el origen de decisión, la longitud L y la maduración de la etiqueta.

Entrenamiento walk-forward

```
for corte in cortes_temporales:
    train = ejemplos_con_etiqueta_observada(corte)
    valid, test = bloques_posteriores(corte)
    scaler.fit(train.X)
    train_X = scaler.transform(train.X)
    valid_X = scaler.transform(valid.X)
    test_X = scaler.transform(test.X)
    modelo = crear_modelo(configuracion)
    modelo.fit(train_X, train.y, valid_X, valid.y)
    pred = modelo.predict(test_X)
    guardar_predicciones_y_metricas(test.y, pred)
```

Pseudocódigo conceptual. La configuración se elige con validación temporal.

Hiperparámetros y estabilidad

Diseño de búsqueda

Comparar lookback, hidden size, capas y learning rate con un presupuesto controlado.

Sobreajuste

Seguir curvas de train y validación, aplicar regularización y recuperar el mejor checkpoint.

Variabilidad

Repetir con varias semillas y reportar resultados por fold, además de la media.

Evaluación y límites del pronóstico

Error y dirección

Reportar métricas fuera de muestra, errores por período y comparación con referencias sencillas.

Información imprevisible

Eventos regulatorios, incidentes y shocks pueden cambiar la distribución del dato.

Uso económico

Una estrategia exige decisiones, costos y ejecución definidos. La precisión sola no establece su resultado.

Actividad LSTM/GRU

Etapa	Trabajo	Evidencia
Datos	Construir una tabla causal	Esquema y timestamps
Ventanas	Definir L, H y F	Ejemplos de entrada y etiqueta
Modelos	Comparar MLP, LSTM y GRU	Configuración y parámetros
Validación	Usar los mismos folds	Predicciones fuera de muestra
Interpretación	Analizar errores y ablación	Tabla de métricas y límites

Bibliografía y documentación

Hochreiter y Schmidhuber (1997). Long Short-Term Memory

<https://www.bioinf.jku.at/publications/older/2604.pdf>

PyTorch. LSTM: ecuaciones, estados y dimensiones

<https://docs.pytorch.org/docs/stable/generated/torch.nn.LSTM.html>

Cho et al. (2014). Learning Phrase Representations using RNN Encoder-Decoder

<https://arxiv.org/abs/1406.1078>

PyTorch. GRU: convención de actualización y candidato

<https://docs.pytorch.org/docs/stable/generated/torch.nn.GRU.html>

Vaswani et al. (2017). Attention Is All You Need

<https://arxiv.org/abs/1706.03762>

Lecturas aplicadas y revisión crítica

Kaur et al. (2025). Cryptocurrency prediction with GRU and LSTM

<https://pmc.ncbi.nlm.nih.gov/articles/PMC11935774/>

Moiz y Raza (2026). Deep learning and GARCH family models

<https://mf-journal.com/article/view/370>

scikit-learn. TimeSeriesSplit

https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html

scikit-learn. Common pitfalls and recommended practices

https://scikit-learn.org/stable/common_pitfalls.html