

UNIDAD 8

GNN aplicadas a blockchain

Representaciones de transacciones, vecindarios y evolución de la red

Representación del grafo

Símbolo	Contenido	Decisión de diseño
V	Conjunto de nodos	Transacción, dirección, contrato o entidad
E	Conjunto de aristas	Flujo, llamada o relación tipificada
X	Características de nodos y aristas	Valor, actividad, tipo y atributos
T	Timestamps o snapshots	Instante de observación y disponibilidad

Construcción del grafo

Representación	Arista	Aplicación y límite
Transacción a transacción	Un output anterior financia un input	Bitcoin y flujo UTXO
Dirección a dirección	Transferencia según una regla declarada	Asignación ambigua con múltiples inputs
Cuenta o contrato	Llamada o evento tipificado	Ethereum y heterogeneidad
Entidad agregada	Relación entre clusters	Depende de heurísticas de agrupación

Métricas clásicas de red

Métrica	Qué resume	Control interpretativo
Grado y strength	Conexiones y peso acumulado	Separar entrada y salida
PageRank	Relevancia según flujos y enlaces	Dirección y ponderación del grafo
Betweenness	Participación en caminos mínimos	Dependencia de la definición de distancia
Clustering	Cierre local de triángulos	Diferente de detección de comunidades
Comunidades	Partición según un criterio estructural	Sensibilidad a resolución y algoritmo

Message passing

$$m_v = \text{AGGREGATE}(\{h_u : u \in N(v)\})$$

$$h_v \text{ nuevo} = \text{UPDATE}(h_v, m_v)$$

Vecindario $N(v)$

Debe especificar si incluye entradas, salidas, ambas o relaciones de un tipo.

Agregación

Combina mensajes de forma compatible con el orden irrelevante de los vecinos.

Aprendizaje

El modelo ajusta cómo representar atributos propios e información relacional.

Ejemplo de agregación por media

$h_v = 2$ vecinos = {1, 3} media = 2

$h_v \text{ nuevo} = \text{ReLU}(0,5 \times 2 + 0,25 \times 2) = 1,5$

Qué se combina

Un atributo propio y un resumen del vecindario con pesos dados para el ejemplo.

Alcance

Ejemplo escalar sintético de message passing. Los pesos reales se aprenden con una tarea.

GCN y normalización

$$\tilde{A} = A + I$$

$$H_{\text{nuevo}} = \varphi(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H W)$$

A y self-loops

A es la adyacencia. I incorpora información del propio nodo. $\tilde{D}$ contiene los grados de $\tilde{A}$.

Normalización

Equilibra contribuciones según el grado. H reúne representaciones y W es aprendible.

Grafos dirigidos

La formulación clásica requiere declarar la adaptación o simetrización elegida.

GraphSAGE: muestreo y agregación

$$\mathbf{m}_v = \text{AGGREGATE}(\{\mathbf{h}_u : u \in \text{muestra de } N(v)\})$$

$$\mathbf{h}_v \text{ nuevo} = \phi(W [\mathbf{h}_v \parallel \mathbf{m}_v])$$

Concatenación ||

Combina atributos propios y representación agregada del vecindario.

Escalabilidad

Muestrear limita el costo del vecindario utilizado por capa.

Inducción

La función aprendida puede aplicarse a nuevos nodos con atributos disponibles.

GAT: atención en el vecindario

$$\alpha_{vu} = \exp(e_{vu}) / \sum_{k \in N(v)} \exp(e_{vk})$$

$$h_v \text{ nuevo} = \varphi(\sum_{u \in N(v)} \alpha_{vu} W h_u)$$

Coeficientes normalizados

En el vecindario definido, los pesos de una cabeza suman 1.

Varias cabezas

Combinan representaciones de atención según la capa y la implementación.

Interpretación

Un peso alto describe una operación del modelo. Su lectura depende del contexto.

Ejemplo de atención ponderada

Vecino	Atributo	Peso ilustrativo
u₁	1	0,10
u₂	2	0,20
u₃	3	0,30
u₄	4	0,40

Mensaje ponderado = $0,10 \times 1 + 0,20 \times 2 + 0,30 \times 3 + 0,40 \times 4 = 3,0$

GCN, GraphSAGE y GAT

Arquitectura	Mecanismo distintivo	Decisión experimental
GCN	Normalización de la adyacencia	Dirección, self-loops y profundidad
GraphSAGE	Muestreo y agregación	Fan-out y protocolo inductivo
GAT	Atención aprendida	Cabezas, vecindario y regularización
Comparación	Mismos datos y etiquetas	Baseline tabular, costo y validación

Bitcoin: el dataset Elliptic

Componente	Cantidad o definición	Uso
Transacciones y flujos	203.769 nodos y 234.355 aristas	Grafo dirigido de transacciones
Características	166 por nodo	94 locales y 72 agregadas
Etiquetas conocidas	4.545 ilícitas y 42.019 lícitas	Entrenamiento y evaluación supervisada
Sin etiqueta conocida	157.205 transacciones	Máscara fuera de la pérdida supervisada
Tiempo	49 pasos	Evaluación cronológica declarada

Etiquetas y clase minoritaria

Máscaras supervisadas

Entrenar y evaluar con etiquetas conocidas y particiones explícitas. Los nodos sin etiqueta pueden participar si el protocolo lo permite.

Métricas relevantes

Reportar precision, recall, F1 y PR-AUC de la clase ilícita, con umbral elegido en validación.

Referencia mínima

Predecir siempre la clase lícita da aproximadamente 90,2 % de accuracy en los nodos etiquetados.

Ethereum: relaciones heterogéneas

Objeto	Observación	Control
EOA y contratos	Cuentas y código ejecutable	Identificador y tipo al instante analizado
Valor nativo	Transferencias de ETH	Diferenciar transacción y trazas
Tokens y protocolos	Eventos, swaps y operaciones DeFi	Contrato, token y decodificación
Approve y llamadas	Autorización o interacción	Una aprobación no es un flujo transferido

Snapshots y evolución temporal

$$\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_t \quad \mathbf{z}_t = \text{READOUT}(\text{GNN}(\mathbf{G}_t))$$

Corte temporal

Cada snapshot incluye nodos, enlaces y atributos disponibles en su período.

Resumen de la red

Readout agrega representaciones de nodos para obtener un vector por snapshot.

Seguimiento

Las métricas o embeddings se pueden comparar en el tiempo y utilizar en un modelo temporal.

Fuga temporal en grafos

Estructura futura

Un enlace posterior al momento de decisión puede revelar actividad que aún no existía.

Atributos agregados

Una centralidad calculada sobre el grafo completo o vecinos futuros puede contaminar entradas.

Etiquetas y splits

Declarar qué nodos, atributos, enlaces y etiquetas conoce cada fold y cada etapa de inferencia.

Tareas y protocolos de evaluación

Tarea	Objetivo	Control
Clasificación de nodos	Etiqueta de transacción o cuenta	Máscaras y desbalance
Predicción de enlaces	Interacción en un período futuro	Muestreo de negativos y corte temporal
Detección de anomalías	Rareza según una referencia	Umbral, revisión y tasa de alertas
Resumen de grafo	Vector o métrica por período	Readout causal y estabilidad
Inductivo o transductivo	Nodos nuevos o grafo parcialmente conocido	Acceso a estructura declarado

Profundidad, heterofilia y límites

Oversmoothing

Con muchas capas, representaciones de nodos pueden volverse demasiado similares.

Heterofilia

Vecinos pueden pertenecer a clases distintas. La mezcla de información necesita evaluación.

Interpretación responsable

Centralidad, atención y anomalía son señales del análisis. Las etiquetas y la identidad exigen evidencia.

Actividad de GNN

Construcción

Crear un grafo pequeño, documentar tipos de nodo, aristas, atributos y timestamps.

Modelos

Comparar métricas clásicas, un baseline tabular y una GNN con configuración declarada.

Evidencia

Entregar máscaras, corte temporal, métricas de la clase relevante y análisis de errores.

Bibliografía y documentación

Kipf y Welling (2017). Semi-Supervised Classification with GCN

<https://arxiv.org/abs/1609.02907>

Hamilton, Ying y Leskovec (2017). Inductive Representation Learning

<https://arxiv.org/abs/1706.02216>

Veličković et al. (2018). Graph Attention Networks

<https://arxiv.org/abs/1710.10903>

Weber et al. (2019). Anti-Money Laundering in Bitcoin

<https://arxiv.org/abs/1908.02591>

Zheng, Zhou y Song (2025). Temporal-Aware Graph Attention Network

<https://arxiv.org/abs/2506.21382>