

UNIDAD 8 · CUADERNO DE LABORATORIOS

Redes neuronales en el tiempo y en la red

Guía completa de ocho simulaciones para Bitcoin, Ethereum y análisis de blockchain

Material elaborado por el profesor Sergio Gevatschnaider.

Profesor Sergio Gevatschnaider · Versión revisada · 2 de octubre de 2026

Bloque	Preguntas centrales
01-04 · Tiempo y evaluación	Ventanas, leakage, métricas, LSTM y GRU.
05-07 · Estructura y memoria	Grafos, centralidad, GNN y pooling recurrente.
08 · Explicabilidad	SHAP lineal, referencia y límites causales.

Datos y mecanismos reproducibles. Actividades guiadas, ejemplos comprobables, vocabulario desarrollado y enlaces a los laboratorios.

[Abrir los ocho laboratorios en el campus →](#)

Antes de experimentar

Qué muestra cada recurso

BTC y ETH son escenarios sintéticos. La arena genera perfiles con coeficientes fijos; no entrena los algoritmos nombrados. Las GNN y las celdas usan pesos fijos. Sólo 02 ajusta una regresión ridge. Un cálculo correcto dentro de la simulación no demuestra rendimiento sobre datos reales.

Controles comunes

Control	Comportamiento
EN / ES	Actualiza textos de interfaz y explicaciones; conserva el experimento.
Modo claro / oscuro	Cambia contraste y colores; conserva configuración y resultados.
Reiniciar	Restaura valores y semilla propios del laboratorio. Idioma y tema se conservan.
Pantalla completa	Amplía la interfaz. Esc permite salir; si el navegador lo restringe, usar F11.
Exportar registro	Descarga JSON con autoría, configuración, supuestos y resultados numéricos.
Descargar gráfico SVG	Exporta la primera visualización como gráfico vectorial.
Marcar actividad realizada	Guarda avance local en este navegador. No evalúa respuestas ni registra una calificación.

Rutina de investigación

1. Anticipá el resultado antes de cambiar un control.
2. Modificá una variable por vez y anotá lo que mantenés fijo.
3. Exportá los dos registros cuando compares configuraciones.
4. Distinguí cálculo exacto, dato sintético, entrenamiento y evidencia empírica.
5. Cerrá con una conclusión y una limitación que el experimento no pueda resolver.

Ruta y registro del experimento

Lab	Tema	Tiempo
01	Ventanas temporales y LSTM	20 min
02	Data Leakage y walk-forward	30 min
03	Arena de pronósticos BTC / ETH	25 min
04	LSTM vs GRU	20 min
05	Blockchain como grafo	25 min
06	GNN: propagación de mensajes	30 min
07	Integrador GNN + LSTM / GRU	30 min
08	Explorador SHAP	25 min

Registro mínimo

Campo	Qué anotar
Pregunta	Qué relación se explora.
Configuración	Semilla, escenario, horizonte y controles.
Resultado	Métrica o traza, unidades y JSON exportado.
Interpretación	Qué cambió al modificar un control.
Límite	Qué requeriría datos, entrenamiento o validación real.

Sugerencia para clase: una pareja anticipa el resultado y otra intenta reconstruirlo con la traza o el registro. Contrastan sus explicaciones antes de leer la orientación de respuesta.

LABORATORIO 01 · 20 MINUTOS

Ventanas temporales y LSTM

Construí una muestra $L \times 2$ y separá contexto de etiqueta futura.

Datos sintéticos · sin entrenamiento

[Abrir laboratorio 01 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Activo	BTC / ETH	Cambia la serie sintética y su semilla; no descarga cotizaciones.
Objetivo	Retorno log / precio $t+1$	Cambia y y sus unidades. X conserva las dos features.
Ventana L	7 a 60	Actualiza L filas completas de la matriz y el conteo train.
Observación t	L-1 a 218	Mueve contexto y etiqueta; el objetivo es $t+1$.

Procedimiento

1. Reiniciá, elegí BTC y retorno log $t+1$. Fijá $t=120$.
2. Compará $L=7, 30$ y 60 ; anotá forma de X y muestras train.
3. Cambiá a precio $t+1$ y distinguí USD de porcentaje.
4. Mové t a 153 y luego a 186; identificá la fecha de y y el conjunto asignado.
5. Exportá un registro y verificá que ninguna fila de X tenga fecha posterior a t.

LABORATORIO 01 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

Con 220 períodos numerados 0 a 219, $L=30$ y $t=120$, X contiene 91 a 120. Su forma es 30×2 y corresponde a 121. Hay 124 targets train, 33 validation y 33 test: 190 muestras. El punto amarillo marca la fecha del target sobre el gráfico de precios aunque el target elegido sea un retorno.

Preguntas de comparación

1. Compará $L=7, 30$ y 60 con BTC y $t=120$. Registrá forma de X y número de muestras train.

Orientación: Las formas son 7×2 , 30×2 y 60×2 ; train tiene 147, 124 y 94 muestras. La etiqueta $t+1$ no entra en X .

2. Mové t hasta cruzar validation y test. ¿Puede una ventana usar contexto del tramo anterior?

Orientación: Sí: se divide por la fecha de la etiqueta. Usar historia conocida es causal; ajustar el escalador con etiquetas o datos futuros no lo es.

Vocabulario del laboratorio 01

Serie temporal · Secuencia de observaciones ordenadas cronológicamente. El índice representa cuándo se observó el dato, no sólo el orden de las filas. Cambiar el orden puede alterar ventanas, etiquetas y evaluación.

Observación · Registro correspondiente a un instante o período de tiempo. Puede corresponder a una dirección, un bloque o un período diario. Debe declararse su unidad y su tiempo de disponibilidad.

Feature · Variable de entrada. Una entrada válida debe estar disponible al decidir. En el laboratorio 01 cada paso aporta dos features: precio y retorno logarítmico.

Target · Variable a predecir. Define la tarea y sus unidades. Cambiar de precio a retorno cambia el significado del error, aunque se conserve la misma ventana de entrada.

Lag · Valor rezagado de una variable. $r(t-1)$ es el retorno del período anterior. El retardo debe calcularse sin desplazar una observación futura hacia una fila anterior.

Ventana temporal · Secuencia fija de observaciones pasadas usada como entrada. Con $L=30$ y $d=2$, una muestra tiene forma 30×2 . Una ventana aporta contexto; no determina por sí sola que una red vaya a aprender mejor.

Secuencia · Orden de datos que preserva la dimensión temporal. El eje temporal es distinto del eje de features. Una matriz $L \times d$ no equivale a d observaciones independientes.

Aprendizaje supervisado · Esquema en el que cada X se asocia con un target y conocido durante el entrenamiento. Las etiquetas permiten minimizar una pérdida. Para validar temporalmente, cada etiqueta de train debe haber madurado antes del corte de entrenamiento.

Retorno · Variación relativa de un activo entre períodos. El retorno simple es $P(t)/P(t-1)-1$; el logarítmico es $\ln[P(t)/P(t-1)]$. Los log-retornos se suman en el horizonte y se convierten con $\exp(r)-1$ para el cálculo económico.

Train · Datos usados para ajustar el modelo. Sus datos ajustan pesos y transformaciones como el escalador. Agregar información posterior al corte crea fuga incluso cuando no se modifican las etiquetas.

Validation · Datos usados para selección y vigilancia de generalización. Sirve para comparar configuraciones y seleccionar checkpoints. Repetir la selección sobre el mismo conjunto puede sobreajustar la decisión del investigador.

Test · Datos reservados para evaluación final. Debe representar datos posteriores no usados en selección. Consultarlo repetidamente para elegir el modelo deja de ser una evaluación final independiente.

Escalado · Transformación de magnitudes a una escala adecuada; debe ajustarse usando sólo Train. Aquí ridge centra y divide cada feature por la desviación estimada en train. Esos mismos parámetros se aplican a test sin volver a ajustarlos.

Orden temporal · Restricción por la cual el pasado precede al futuro en la construcción y evaluación. La disponibilidad efectiva puede ser posterior al timestamp del evento. Respetar el orden exige considerar publicación, revisiones y maduración de etiquetas.

Data leakage · Uso indebido de información que no estaría disponible al predecir. Puede entrar por features, escaladores, etiquetas, selección o estructura del grafo. Un split cronológico no elimina automáticamente todas estas fuentes.

LABORATORIO 02 · 30 MINUTOS

Data Leakage y walk-forward

Detectá fuga de información y purgá etiquetas que todavía no están disponibles.

Ridge ajustada · datos sintéticos

[Abrir laboratorio 02 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Leakage	OFF / ON	Agrega o retira $0,15r(t)+0,85y(t,H)$.
Walk-forward	ON / OFF	Compara reajuste por fold con holdout temporal.
Horizonte H	1 / 7	Acumula H retornos y excluye etiquetas no maduras.

Procedimiento

1. Reiniciá y conservá walk-forward ON, $H=1$ y leakage OFF.
2. Anotá RMSE, MAE, acierto de dirección y R^2 . Exportá el registro.
3. Activá leakage y repetí sobre los mismos folds. No cambiés el horizonte todavía.
4. Volvé a OFF, elegí $H=7$ e inspeccioná las seis filas purgadas por fold.
5. Desactivá walk-forward y compará el rango de evaluación: es otro test, no una comparación idéntica.

LABORATORIO 02 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

Con $H=7$ el primer test comienza en $t=135$. El último origen permitido en train es 128, cuya etiqueta termina en 135. Los seis orígenes 129 a 134 se excluyen porque aún no tienen etiqueta completa al corte. El proxy con fuga contiene la etiqueta futura aun después de hacer esa purga.

Preguntas de comparación

1. Compará leakage OFF/ON manteniendo horizonte y folds. Exportá ambos registros.

Orientación: La variable contaminada contiene 85% de la etiqueta futura; una mejora de métricas no demuestra generalización.

2. Elegí $H=7$. ¿Por qué se excluyen filas al final de train?

Orientación: Se purgan 6 orígenes cuya etiqueta termina después del primer instante de decisión test. Walk-forward no corrige una feature que ya contiene futuro.

Vocabulario del laboratorio 02

Data leakage · Uso indebido de información que no estaría disponible al predecir. Puede entrar por features, escaladores, etiquetas, selección o estructura del grafo. Un split cronológico no elimina automáticamente todas estas fuentes.

Look-ahead bias · Sesgo causado por utilizar información del futuro al construir features, seleccionar modelos o evaluar resultados. Por ejemplo, una media centrada contiene datos posteriores a t . La auditoría debe preguntar qué habría podido calcularse en tiempo real.

FutureProxy · Variable pedagógica contaminada que codifica parte del target futuro. En el laboratorio 02 es $0,15r(t)+0,85y(t,H)$. Su buena relación con y se construye deliberadamente y no puede usarse al predecir.

Regresión ridge · Regresión lineal con penalización L2 para reducir coeficientes excesivos. Minimiza error cuadrático más λ por la suma de coeficientes al cuadrado. El laboratorio utiliza $\lambda=0,1$, features escaladas y un intercepto sin penalización.

Regularización L2 · Penalización proporcional al cuadrado de los coeficientes del modelo. Reduce la magnitud de pesos de manera continua. Su efecto depende de la escala de las features y de cómo se define la función objetivo.

RMSE · Raíz del error cuadrático medio. Se calcula como $\sqrt{\text{media}[(\hat{y}-y)^2]}$ y conserva las unidades de y . Penaliza más los errores grandes; aquí los retornos se informan en puntos porcentuales.

MAE · Error absoluto medio. Se calcula como $\text{media}[|\hat{y}-y|]$ y conserva las unidades de y . Permite interpretar un error típico sin elevar al cuadrado los desvíos.

Directional Accuracy · Proporción de signos correctamente anticipados. Compara $\text{sign}(\hat{y})$ con $\text{sign}(y)$. Un pronóstico de retorno cero no expresa una dirección; en la arena esa métrica se omite para el baseline cash.

R^2 · Métrica de ajuste relativa a una referencia basada en la media. Se calcula como $1-\text{SSE}/\text{SST}$. Puede ser negativo fuera de muestra; no mide rentabilidad y es indefinido si el target no tiene variación.

Split temporal · Separación de datos que preserva orden cronológico. Se asignan muestras por fecha de etiqueta o por una regla documentada de origen. Las ventanas test pueden utilizar historia anterior que ya era conocida.

Walk-forward validation · Evaluación secuencial que entrena con el pasado y prueba en períodos posteriores. En cada fold se vuelve a ajustar el modelo con información disponible al nuevo corte. Permite observar variación entre períodos, pero no repara features contaminadas.

Fold temporal · Cada corte o iteración de una validación walk-forward. Debe registrar último origen train, última fecha de etiqueta y rango test. Los errores de targets de H períodos que se superponen no son independientes.

Out-of-sample · Datos no utilizados para ajustar el modelo. Excluir datos del ajuste es necesario, pero también hay que excluirlos de la selección. La expresión no garantiza que las features estén libres de fuga.

Feature legítima · Variable que puede conocerse realmente al momento de producir la predicción. Su construcción, sus revisiones y sus fuentes deben ser conocidas al corte. Un registro histórico reconstruido después puede no ser legítimo en una evaluación retrospectiva.

Target futuro · Resultado que ocurre después del tiempo de decisión y no debe filtrarse a X . Para $H=7$ depende de siete retornos posteriores. Su etiqueta sólo puede ingresar a train cuando esos siete períodos ya fueron observados.

LABORATORIO 03 · 25 MINUTOS

Arena de pronósticos BTC / ETH

Contrastá seis perfiles sintéticos con métricas calculadas y costos explícitos.

Perfiles sintéticos · sin entrenamiento

[Abrir laboratorio 03 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Escenario	BTC / ETH	Cambia un proceso sintético con parámetros conocidos.
Horizonte	1 / 7	Evalúa retornos log acumulados en 90 orígenes.
Familias de features	Mercado / técnica / on-chain	Activa términos causales prefijados; no ajusta algoritmos.
Costo	0 a 50 bp	Costo × cambio de posición . Pasar de -1 a +1 cuesta dos unidades.

Procedimiento

1. Reiniciá, inspeccioná la advertencia de perfiles y el baseline cash.
2. Activá on-chain manteniendo BTC, H=1 y los otros controles.
3. Cambiá a ETH: anotá que cambió el proceso sintético y no un mercado descargado.
4. Fijá H=7 y compará costos 0 y 30 bp.
5. Separá en tu informe error predictivo, dirección y riesgo económico.

LABORATORIO 03 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

La fila Naive predice 0 en los 90 orígenes. Por ello $RMSE = \sqrt{\text{media}[y^2]}$ y $MAE = \text{media}[|y|]$. Las posiciones permanecen en cash, su drawdown es 0 y su Sharpe no se define porque la desviación es 0. Con H=7 se toman 13 decisiones separadas por siete períodos; las métricas predictivas usan los 90 targets y pueden solaparse.

Preguntas de comparación

1. Activá on-chain, cambiá BTC/ETH y compará RMSE con baseline.

Orientación: El resultado depende del proceso sintético y de coeficientes prefijados. Ninguno de los seis algoritmos nombrados se entrena aquí.

2. Compará costos 0 y 30 bp con H=7. ¿Cambian RMSE y Sharpe de la misma manera?

Orientación: RMSE no cambia: el pronóstico permanece fijo. Sharpe y drawdown se recalculan con retornos netos y decisiones sin solapamiento.

Vocabulario del laboratorio 03

Baseline · Referencia declarada para evaluar pronósticos o para descomponer una salida explicada. En evaluación es un pronóstico de referencia; en SHAP es el valor esperado bajo un juego explicativo. Estos dos usos responden a preguntas distintas.

Naive · Baseline que usa una regla muy simple, por ejemplo persistencia o ausencia de cambio. En la arena elige retorno pronosticado cero y posición cash. En otros problemas puede ser persistencia: conviene declarar siempre la regla concreta.

AR · Modelo autorregresivo que usa valores pasados de la variable para estimar el futuro. Su versión real ajusta coeficientes de retardos en train. La arena muestra un perfil causal prefijado inspirado en AR; no estima ese modelo.

Random Forest · Ensamble de árboles de decisión entrenados sobre muestras y subconjuntos de variables. Combina predicciones de muchos árboles para reducir variabilidad. El nombre de la arena identifica un perfil sintético: no se construyen ni ajustan árboles allí.

XGBoost · Algoritmo de gradient boosting basado en árboles, optimizado para aprendizaje tabular. Construye árboles sucesivos que corrigen el objetivo de entrenamiento con regularización. La arena no ejecuta boosting ni constituye un benchmark del algoritmo.

LSTM · Red recurrente Long Short-Term Memory con memoria explícita. Una red recurrente con estado de celda c y estado oculto h , controlados por compuertas de entrada, olvido y salida. Su utilidad debe contrastarse con baselines bajo el mismo protocolo.

GRU · Red recurrente Gated Recurrent Unit con estado oculto y dos compuertas. Una red recurrente que utiliza compuertas de actualización y reset sin una celda c separada. Aquí $h = (1-z)g + zh_{\text{anterior}}$; un z alto conserva más estado anterior.

Feature set · Conjunto de variables disponibles para un modelo. Debe describir disponibilidad, unidades y transformaciones. Una comparación por ablación cambia una familia de entradas y mantiene el protocolo restante.

Features de mercado · Variables como precio, retorno, volumen o volatilidad. Su frecuencia y su fuente deben ser consistentes con el target. En la arena sólo se usa un término sintético derivado del retorno actual.

Indicadores técnicos · Transformaciones de precios/volumen como medias móviles, RSI o MACD. Una transformación no aporta datos futuros si sólo utiliza historia disponible. El laboratorio 03 usa una onda sintética, no RSI o MACD calculados de un mercado real.

Features on-chain · Variables derivadas de la actividad registrada en la blockchain. Requieren una definición de bloques, confirmaciones, ventanas y unidad de análisis. En la arena el término on-chain es una onda pedagógica y no un dato de explorador.

Horizonte · Distancia entre instante de información y target futuro. Aquí H cuenta períodos diarios sintéticos. Cambiar H modifica etiqueta, disponibilidad, solapamiento y frecuencia de decisiones económicas.

Sharpe Ratio · Relación entre retorno excedente y volatilidad. En la arena se estima $\text{media}(\text{retorno neto})/\text{desviación muestral} \times \sqrt{(365/H)}$, con tasa libre cero. Esa anualización presupone una escala temporal y no prueba estabilidad de la estrategia.

Max Drawdown · Mayor caída desde un máximo a un mínimo posterior. Se calcula como el máximo de 1-riqueza/máximo previo. Depende de la secuencia de retornos netos, no sólo de su promedio.

Same split · Principio de comparar modelos sobre exactamente los mismos períodos. Los targets y orígenes de evaluación deben coincidir. En la arena los 90 orígenes son idénticos, aunque no se realiza entrenamiento de los perfiles.

Same metrics · Principio de evaluar todos los modelos con la misma definición de métricas. También deben coincidir unidades, definición de cero, costos y anualización. Compartir únicamente el nombre de una métrica no hace comparables dos estudios.

LABORATORIO 04 · 20 MINUTOS

LSTM vs GRU

Compará parámetros exactos y observá curvas pedagógicas de pérdida.

Conteo exacto · curvas sintéticas

[Abrir laboratorio 04 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Arquitectura	LSTM / GRU	Cambia 4 / 3 bloques de parámetros.
input_dim d	1 a 24	Número de features por paso; afecta el conteo.
Unidades u	8 a 128	Dimensión recurrente y capacidad ilustrativa.
Bias	1 / 2 vectores	Uno es la convención simplificada; dos coincide con PyTorch.
Dropout	0 a 0,6	Modifica sólo una fórmula de curvas ilustrativas.
Épocas	20 a 150	Muestra más puntos de la curva; no ejecuta optimización.

Procedimiento

1. Reiniciá con $d=8$, $u=32$ y dos biases. Compará LSTM y GRU.
2. Elegí un bias y verificá el desglose del conteo.
3. Variá unidades manteniendo los otros parámetros.
4. Compará dropout 0, 0,2 y 0,6 con 150 épocas.
5. Ubicá el mínimo de validation y explicá por qué las curvas no son evidencia de entrenamiento.

LABORATORIO 04 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

Para $d=8$, $u=32$ y dos vectores de bias, LSTM suma $4 \cdot 32 \cdot 8 = 1.024$ pesos de entrada, $4 \cdot 32^2 = 4.096$ recurrentes y $4 \cdot 32 \cdot 2 = 256$ biases: 5.376. GRU suma $768 + 3.072 + 192 = 4.032$. Elegir un bias cambia a 5.248 y 3.936. El conteo no incluye cabeza de salida ni otra capa.

Preguntas de comparación

1. Con $d=8$ y $u=32$, compará LSTM/GRU y uno/dos vectores de bias.

Orientación: Con dos biases: LSTM 5.376 y GRU 4.032. Con uno: 5.248 y 3.936. Una capa, una dirección, sin cabeza de salida.

2. Variá dropout de 0 a 0,6 y épocas de 20 a 150. Identificá el mínimo de validación.

Orientación: Las curvas se generan con una fórmula y muestran un compromiso ilustrativo. No miden desempeño real ni prueban superioridad de una arquitectura.

Vocabulario del laboratorio 04

RNN · Red neuronal recurrente diseñada para procesar secuencias y mantener un estado entre pasos. Actualiza $h(t)$ a partir de entrada actual y estado anterior. Una red recurrente puede procesar secuencias, pero también sufrir problemas de gradiente y memoria efectiva.

LSTM · Red recurrente Long Short-Term Memory con memoria explícita. Una red recurrente con estado de celda c y estado oculto h , controlados por compuertas de entrada, olvido y salida. Su utilidad debe contrastarse con baselines bajo el mismo protocolo.

GRU · Red recurrente Gated Recurrent Unit con estado oculto y dos compuertas. Una red recurrente que utiliza compuertas de actualización y reset sin una celda c separada. Aquí $h=(1-z)g+zh_{anterior}$; un z alto conserva más estado anterior.

input_dim · Cantidad de variables de entrada por paso temporal. Es d , no L : describe cuántas variables tiene cada paso. En el laboratorio 01 $d=2$ y L puede cambiar sin modificar esa cantidad.

Units · Dimensión del estado oculto recurrente. Es u , el tamaño de h y de c en LSTM sin proyección. Aumentarlo eleva especialmente el término recurrente u^2 del conteo de parámetros.

Parámetro · Peso o bias aprendido durante el entrenamiento. Las compuertas comparten sus matrices a lo largo de los pasos temporales. Cambiar la longitud de secuencia no agrega matrices nuevas a una celda estándar.

Input gate · Compuerta LSTM que regula cuánto contenido nuevo ingresa al estado de celda. Sus valores sigmoides entre 0 y 1 multiplican el candidato g . No selecciona ejemplos completos; regula coordenadas de memoria.

Forget gate · Compuerta LSTM que regula cuánto del estado previo se conserva. Multiplica $c(t-1)$ en $c(t)=f \cdot c(t-1)+i \cdot g$. No es una medida directa de importancia económica del pasado.

Output gate · Compuerta LSTM que regula qué parte del estado de celda se expone como hidden state. Calcula $h(t)=o \cdot \tanh[c(t)]$. Distingue memoria interna de la parte expuesta a la siguiente transformación.

Cell state · Memoria interna de una LSTM. Acumula candidato y memoria previa mediante compuertas. En el integrador es un escalar para facilitar el cálculo; una LSTM real puede usar un vector grande.

Hidden state · Estado recurrente que resume información previa. Resume el prefijo procesado y alimenta el siguiente paso. No debe confundirse con una predicción final o una etiqueta.

Update gate · Compuerta GRU que combina estado previo y candidato nuevo. Su interpretación depende de la convención algebraica. En esta unidad un z próximo a 1 retiene h anterior; próximo a 0 incorpora el candidato.

Reset gate · Compuerta GRU que controla cuánto del pasado interviene al construir el candidato. En la variante escalar usada aquí modula $r \cdot (0,38h_{\text{anterior}})$ dentro del candidato. No controla directamente la mezcla final de h .

Dropout · Regularización que desactiva unidades durante entrenamiento. Durante entrenamiento aplica máscaras aleatorias y reescala activaciones según su implementación. PyTorch lo aplica entre capas recurrentes; el laboratorio 04 sólo modifica curvas sintéticas.

Epoch · Una pasada completa por el conjunto de entrenamiento. No equivale a un batch ni a una actualización de parámetros. Aquí el eje de épocas es ilustrativo y no ejecuta optimización.

Loss · Función que cuantifica error y guía el ajuste de parámetros. Su elección depende del target. Una pérdida baja en train no basta para establecer generalización ni calidad económica.

Validation loss · Error calculado sobre datos de validación. No participa normalmente del gradiente de entrenamiento. Su mínimo puede usarse para seleccionar un checkpoint según una regla fijada previamente.

Generalization gap · Diferencia entre error de entrenamiento y validación. Aquí es $\text{loss_validation} - \text{loss_train}$ al final de las épocas mostradas. Cambios de distribución también pueden ampliar esa brecha.

Overfitting · Ajuste excesivo a Train con peor generalización. Puede afectar pesos, hiperparámetros o selección de estrategias. Una curva ilustrativa ayuda a reconocer el patrón, pero no diagnostica un modelo real.

Early stopping · Detención del entrenamiento cuando Validation deja de mejorar. Se define mediante paciencia, mejora mínima y restauración del checkpoint. El laboratorio sólo marca el mínimo observado y no ejecuta esa regla.

LABORATORIO 05 · 25 MINUTOS

Blockchain como grafo

Explorá direcciones, aristas dirigidas, fuerza y centralidad.

Grafo sintético · centralidad calculada

[Abrir laboratorio 05 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Direcciones	6 a 16	Cambia n del grafo dirigido simple.
Probabilidad p	0,12 a 0,42	Cambia el generador; no fija exactamente la densidad.
Regenerar	Semilla +1	Crea otra realización y muestra la semilla.
Seleccionar	Clic / teclado / lista	Inspecciona métricas y vínculos de una dirección.
PageRank ponderado	OFF / ON	Usa conteos de transacciones en las transiciones.

Procedimiento

1. Reiniciá y anotá n, p, semilla y densidad observada.
2. Seleccioná una dirección con la lista o con Enter sobre un nodo.
3. Contrastá degree con fuerza usando la tabla de vínculos.
4. Activá PageRank ponderado sin regenerar; compará ranking.
5. Regenerá y después reiniciá: comprobá que vuelve la semilla 2026.

LABORATORIO 05 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

Con 10 direcciones hay $10 \cdot 9 = 90$ aristas dirigidas posibles. Si la realización contiene 22, la densidad es $22/90 \approx 0,244$. Una dirección con dos aristas entrantes de pesos 3 y 8 tiene $\text{in-degree} = 2$ y fuerza entrante = 11. Los pesos no representan 3 u 8 unidades monetarias.

Preguntas de comparación

1. Elegí una dirección con vínculos entrantes y salientes. Diferenciá degree y strength.

Orientación: Degree cuenta contrapartes en este grafo simple; strength suma los pesos, definidos como conteos de transacciones agregadas.

2. Activá PageRank ponderado manteniendo la misma semilla.

Orientación: Los pesos cambian las probabilidades de transición. La suma de PageRank es 1; betweenness permanece no ponderada. Una dirección no identifica necesariamente una persona.

Vocabulario del laboratorio 05

Grafo · Estructura formada por nodos y aristas. Su significado depende de qué representa cada nodo y vínculo. Un grafo de direcciones no equivale a un grafo de transacciones, bloques o contratos.

Nodo · Unidad de un grafo. En el laboratorio 05 representa una dirección sintética. En otros diseños puede representar una transacción o un contrato; esa decisión cambia la tarea.

Arista · Relación definida entre dos nodos de un grafo. En 05 agrega transacciones dirigidas entre dos direcciones; su peso cuenta eventos. En 06 y 07 representa una relación no dirigida de un grafo simplificado.

Grafo dirigido · Grafo cuyas aristas tienen origen y destino. El vínculo A->B no implica B->A. PageRank y betweenness se calculan respetando esos sentidos en el laboratorio 05.

Wallet · Software o dispositivo para gestionar claves y direcciones de una blockchain. Es una herramienta para gestionar claves y direcciones, no una identidad verificada. El laboratorio utiliza direcciones sintéticas como nodos y no agrupa usuarios.

Transacción · Evento registrado en la blockchain según su modelo de ejecución. Un evento real puede tener múltiples entradas, salidas o llamadas. Las aristas del laboratorio son una agregación didáctica y no reproducen íntegramente UTXO o EVM.

Densidad · Proporción de conexiones existentes respecto de las posibles. En un grafo dirigido simple sin self-loops es $m/[n(n-1)]$. La probabilidad p del generador no tiene por qué coincidir exactamente con la densidad observada.

Degree · Cantidad total de conexiones asociadas a un nodo. En un grafo simple cuenta aristas incidentes o contrapartes según la convención. No suma transacciones repetidas agregadas: esa cantidad corresponde a strength.

In-degree · Número de aristas que llegan al nodo. Cuenta vínculos de contrapartes que llegan a la dirección. Su fuerza entrante suma los pesos y puede ser mucho mayor.

Out-degree · Número de aristas que salen del nodo. Cuenta vínculos hacia contrapartes de destino. No debe confundirse con el importe transferido ni con número total de eventos.

Centralidad · Medida de posición o importancia estructural en un grafo. Cada medida responde a una definición de posición estructural. Ninguna demuestra por sí sola identidad, riesgo, fraude o influencia económica.

PageRank · Centralidad que pondera la calidad de los vínculos entrantes. Distribuye masa por enlaces salientes con damping 0,85 y redistribución de nodos sin salida. El modo ponderado usa proporciones de conteos de transacciones.

Betweenness · Centralidad basada en la intermediación de un nodo en caminos cortos. Suma fracciones de caminos mínimos entre pares que pasan por el nodo. Aquí es dirigida, no ponderada y normalizada por $(n-1)(n-2)$.

Camino corto · Secuencia de aristas con mínima longitud entre dos nodos. En 05 la longitud es el número de aristas, no sus pesos. Si se usan pesos como distancias debe declararse por qué una cantidad de transacciones representaría distancia.

Topología de red · Forma global en que nodos y conexiones se organizan. Incluye conectividad, componentes y distribución de vínculos. Dos nodos con la misma feature pueden tener contexto estructural distinto.

Intermediación · Rol de un nodo como puente entre regiones de la red. Un puente puede concentrar caminos mínimos sin tener muchos vecinos. La interpretación depende del grafo observado y sus omisiones.

LABORATORIO 06 · 30 MINUTOS

GNN: propagación de mensajes

Seguí cada coeficiente y transformación de GCN, GraphSAGE y GAT.

Pesos fijos · cálculo de capas

[Abrir laboratorio 06 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Arquitectura	GCN / GraphSAGE / GAT	Cambia la regla de agregación y transformación.
Nodo	A a F	Muestra embedding, coeficientes y traza.
Capa L	0 a 6	En 0 no hubo agregación; luego aplica pesos fijos.
Avanzar	Una capa	Permite comparar la propagación y el campo receptivo.

Procedimiento

1. Reiniciá: A, GCN, capa 1. Recalculé agregado y salida con la matriz visible.
2. Elegí capa 0 y comprobá que no se muestran coeficientes de agregación.
3. Compará GraphSAGE y GAT en la misma capa y nodo.
4. En GAT sumá pesos; en GCN explicá por qué no tienen que sumar 1.
5. Avanzá hasta capa 6 y registrá el campo receptivo sin inferir desempeño.

LABORATORIO 06 · RECONSTRUIR E INTERPRETAR**Un resultado que podés comprobar**

En GCN, A tiene dos vecinos B y C. Con self-loops los grados son 3, 4 y 5. Los coeficientes para A, B y C son $1/3$, $1/\sqrt{12}$ y $1/\sqrt{15}$: suman aproximadamente 0,8802. El agregado de sus dos features es [0,53847; 0,45253] y la salida H·W seguida de ReLU es [0,52128; 0,56882].

Preguntas de comparación**1. Seleccioná A, capa 1 y compará GCN, GraphSAGE y GAT. Reconstruí la traza.**

Orientación: GCN usa coeficientes simétricos y self-loop; GraphSAGE concatena estado propio y media; GAT aplica softmax sobre scores con pesos fijos.

2. Explorá capas 0 a 6. ¿Qué ocurre con el campo receptivo?

Orientación: Puede alcanzar vecinos a L saltos. Los coeficientes GCN no necesariamente suman 1; GAT sí. Más capas no prueban mejor clasificación.

Vocabulario del laboratorio 06

GNN · Graph Neural Network: familia de redes para datos con estructura de grafo. Una red que actualiza representaciones a partir de features y relaciones. En 06 sus pesos son fijos; las representaciones se calculan sin entrenamiento.

Message passing · Intercambio y agregación de información entre nodos vecinos. Cada capa combina mensajes del estado de la capa anterior. Las actualizaciones son simultáneas; no se usan vecinos parcialmente actualizados en la misma ronda.

Embedding · Representación vectorial de un nodo, grafo o estado. Es un vector dependiente del encoder y sus parámetros. Una coordenada mayor no significa mayor riesgo ni mejor precisión por sí sola.

Node feature · Variable inicial asociada a un nodo. En 06 cada nodo tiene dos valores sintéticos. En un estudio real se deben definir unidades, disponibilidad y escalado de todas las features.

Neighborhood · Conjunto de vecinos conectados a un nodo. Se define por las aristas y su dirección. En 06 y 07 se utiliza vecindario no dirigido como simplificación explícita.

Aggregate · Operación que resume mensajes de los vecinos. Puede usar suma ponderada, media o atención. Debe preservar invariancia ante el orden de vecinos cuando la arquitectura lo exige.

Update · Transformación que produce el nuevo estado del nodo. Aplica una transformación y una activación después de agregar. En GraphSAGE se conserva el estado propio mediante concatenación.

Layer · Una ronda de message passing y transformación. Tras L capas puede incorporarse información hasta L saltos. El campo receptivo es potencial: pesos y activaciones pueden atenuar mensajes.

Self-loop · Conexión del nodo consigo mismo para conservar información propia en la agregación. GCN y GAT incluyen el propio nodo entre las fuentes. GraphSAGE conserva su estado por concatenación y promedia sólo vecinos externos.

GCN · Graph Convolutional Network con agregación normalizada. Usa $H_{\text{nuevo}} = \text{ReLU}[\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H W]$. Sus coeficientes simétricos no necesariamente suman 1 y no equivalen a un simple promedio por fila.

GraphSAGE · Arquitectura GNN basada en agregación de vecinos. La variante mean concatena $[h_{\text{propio}} || \text{mean}(\text{vecinos})]$ y proyecta con W_S . Este laboratorio usa todos los vecinos y omite normalización L2 posterior.

GAT · Graph Attention Network con atención entre vecinos. Una cabeza calcula scores $\text{LeakyReLU}(a^T [W_h v || W_h u])$ y softmax sobre vecinos más self. La atención depende de features y parámetros fijos aquí.

Attention · Mecanismo que asigna pesos relativos a distintas fuentes de información. Pondera fuentes antes de agregarlas. Un peso de atención no es automáticamente una explicación causal ni una medida de importancia global.

Softmax · Función que convierte scores en pesos positivos normalizados. $\text{Exp}(a_i) / \sum \text{Exp}(a_j)$ convierte scores en pesos que suman 1. Para estabilidad numérica se resta el máximo de los scores antes de exponenciar.

Attention weight · Peso asignado a un vecino por el mecanismo de atención. En 06 incluye el self-loop y se calcula para la capa seleccionada. No debe mostrarse como si existiera agregación cuando $L=0$.

ReLU · Función de activación $\max(0, x)$. Se aplica por coordenada y deja pasar valores positivos. Puede hacer cero una contribución transformada negativa.

Representación oculta · Estado intermedio de un nodo dentro de la red. Surge después de agregar y transformar. Para comparar modelos hay que evaluar una tarea, no sólo comparar tamaños de embeddings.

Receptive field · Conjunto de nodos cuya información puede influir en la representación tras varias capas. En el grafo no dirigido puede crecer hasta L saltos. Llegar a todo el grafo no garantiza conservar información discriminativa.

Over-smoothing · Fenómeno por el cual muchas capas hacen que representaciones de nodos se vuelvan demasiado similares. Depende de arquitectura, conectividad, pesos y profundidad. Observar vectores parecidos en este ejemplo no demuestra un límite universal de las GNN.

LABORATORIO 07 · 30 MINUTOS

Integrador GNN + LSTM / GRU

Recorré snapshots, pooling y compuertas de una celda recurrente.

Pesos fijos · prefijo causal

[Abrir laboratorio 07 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
GNN	GCN / GraphSAGE / GAT	Encoder de una capa, compartido entre snapshots.
Temporal	LSTM / GRU	Celda escalar con pesos fijos y estado inicial cero.
Anterior / siguiente	Snapshots 1 a 5	Calcula sólo el prefijo disponible hasta t.
Reproducir / pausar	Avance automático	Recorre estados cada 1,2 segundos; se detiene al final.

Procedimiento

1. Reiniciá con GCN y LSTM en snapshot 1.
2. Verificá vector global, densidad y proyección escalar.
3. Avanzá hasta snapshot 3; observá que 4 y 5 siguen pendientes.
4. Reconstruí c y h usando la traza de compuertas; después compará GRU.
5. Reproducí la secuencia y justificá qué etiquetas y entrenamiento faltarían en un experimento real.

LABORATORIO 07 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

El encoder produce cinco embeddings de dos coordenadas. Su media da dos valores; concatenar densidad crea un vector global de tres coordenadas. Se calcula $x=0,85z_1+0,55z_2+0,35z_3$ y se actualiza una celda escalar. En GRU, si $z=0,6$, candidato $g=0,4$ y $h_{anterior}=0,2$, $h=0,4 \cdot 0,4+0,6 \cdot 0,2=0,28$.

Preguntas de comparación

1. Avanzá snapshot por snapshot y verificá pooling y estado de celda.

Orientación: Se promedian 5 embeddings, se concatena densidad y se proyecta a x escalar. Sólo se calculan estados hasta el cursor actual.

2. Cambiá LSTM a GRU y reconstruí h con las compuertas visibles.

Orientación: La convención GRU es $h=(1-z) \cdot g + z \cdot h_{\text{anterior}}$. El score sigmoide 0-1 es adimensional, sin calibración ni entrenamiento.

Vocabulario del laboratorio 07

Grafo dinámico · Grafo cuya estructura o features cambian con el tiempo. Los snapshots deben construirse con eventos conocidos al corte. Usar aristas futuras al resumir un estado anterior produciría fuga estructural.

Snapshot · Estado de un grafo en un tiempo dado. Tiene una ventana de agregación y un tiempo de disponibilidad. En 07 se muestran cinco grafos sintéticos consecutivos.

Graph embedding · Vector que resume información de un grafo completo. El pooling convierte varios embeddings de nodo en un vector global. En 07 se usa media de cinco nodos y se concatena densidad.

z(t) · Embedding del snapshot en el instante t. En la notación conceptual es el vector global del snapshot. Para evitar confusión, z de la compuerta GRU es otro objeto: un factor escalar de retención.

Secuencia temporal · Orden de embeddings o estados a través del tiempo. La celda procesa únicamente el prefijo observado. Mostrar resultados futuros como disponibles en t alteraría la interpretación causal.

Celda recurrente · Unidad LSTM o GRU que actualiza memoria a cada paso. Comparte pesos entre pasos y conserva estado. En el integrador es escalar y parte de $h_0=c_0=0$ para permitir una traza manual.

Hidden state · Estado recurrente que resume información previa. Resume el prefijo procesado y alimenta el siguiente paso. No debe confundirse con una predicción final o una etiqueta.

Cell state · Memoria interna de una LSTM. Acumula candidato y memoria previa mediante compuertas. En el integrador es un escalar para facilitar el cálculo; una LSTM real puede usar un vector grande.

Temporal graph model · Modelo que combina estructura de grafo y dependencia temporal. Debe decidir si recurre sobre estados de nodo o sobre un resumen global. La arquitectura aquí usa un resumen global por snapshot.

Sampling · Regla para seleccionar nodos, vecinos, aristas o snapshots durante entrenamiento. Puede reducir costo, pero cambia el vecindario observado. Los laboratorios 06 y 07 no muestrean: emplean todos los vecinos.

Label · Resultado objetivo asociado a nodo, arista, grafo o período. Su disponibilidad puede retrasarse respecto del evento. Es necesario auditar ese retraso antes de incorporarla a entrenamiento.

Window · Conjunto de snapshots pasados utilizado como contexto. En un modelo de snapshots define cuánta historia de grafos se procesa. No equivale necesariamente a la ventana de agregación de transacciones de cada grafo.

Temporal validation · Evaluación que respeta la secuencia pasada -> futuro. También exige que aristas y features pertenezcan al pasado. Separar sólo etiquetas no impide fuga en la estructura.

Pipeline · Cadena completa de transformaciones desde datos hasta output. Debe especificar dimensiones y unidades en cada transformación. En 07 pasa de 5×2 a un vector global de 3, luego a x escalar y estado escalar.

Signal · Salida pedagógica final del simulador; no equivale a recomendación financiera. En 07 se muestra un score adimensional generado por pesos fijos. Su rango 0-1 no lo convierte en una probabilidad calibrada.

Sigmoid · Función que transforma un valor real a un número entre 0 y 1. $\sigma(a) = 1/(1 + \exp(-a))$. Es una transformación matemática; la interpretación probabilística requiere una tarea y calibración adecuadas.

Graph-level task · Problema cuyo target corresponde al grafo completo y no a un nodo individual. Por ejemplo, predecir una propiedad del snapshot completo. Requiere pooling u otra lectura global y un target que corresponda a esa misma unidad.

LABORATORIO 08 · 25 MINUTOS

Explorador SHAP

Reconstruí la salida de un modelo lineal y cambiá su referencia.

Modelo lineal · SHAP exacto bajo supuestos

[Abrir laboratorio 08 →](#)

Controles y consecuencias

Control	Valores	Qué modifica
Activo	BTC / ETH	Selecciona coeficientes y features de un modelo lineal distinto.
Features x	0 a 1	Cambia la observación, no los coeficientes.
Referencia μ	0,2 a 0,8	Cambia medias de fondo, baseline y contribuciones; mantiene $f(x)$.
Observación de referencia	$x=\mu$	Hace cero todas las contribuciones del juego independiente.

Procedimiento

1. Reiniciá BTC y verificá los cinco términos $w(x-\mu)$.
2. Comprobá suma, baseline, salida y residuo numérico.
3. Mové sólo μ de 0,50 a 0,60: registrá que $f(x)$ no cambia.
4. Elegí observación de referencia y comprobá $\phi=0$.
5. Cambiá a ETH y explicá por qué atribución local no equivale a causalidad.

LABORATORIO 08 · RECONSTRUIR E INTERPRETAR

Un resultado que podés comprobar

Con BTC inicial, $w=[-0,75; 0,42; 0,55; 0,30; -0,18]$, $x=[0,72; 0,66; 0,58; 0,62; 0,44]$ y $\mu=0,50$, $\phi=[-0,1650; 0,0672; 0,0440; 0,0360; 0,0108]$. La suma es $-0,0070$ y $f(x)=0,0130$ con baseline $0,0200$. El intercepto permanece $b=-0,15$. Si μ cambia a $0,60$, $\text{baseline}=0,0540$ y $\Sigma\phi=-0,0410$: la salida sigue en $0,0130$.

Preguntas de comparación

1. Con BTC y $\mu=0,50$ verificá baseline, contribuciones y salida.

Orientación: Base=0,0200; $\Sigma\phi=-0,0070$; $f(x)=0,0130$. La suma debe cerrar salvo redondeo.

2. Cambiá μ y mantené x fijo. Después elegí observación de referencia.

Orientación: Cambian baseline y contribuciones, no $f(x)$. Si $x=\mu$ todas las contribuciones son cero. La fórmula es exacta para el juego interventional independiente, no para SHAP condicional con correlación.

Vocabulario del laboratorio 08

Explainability · Conjunto de técnicas para hacer comprensible el comportamiento de un modelo. Describe comportamiento del modelo bajo un método y una referencia. Debe evaluarse estabilidad y adecuación al objetivo de explicación.

Interpretability · Grado en que una persona puede comprender cómo un modelo produce una salida. Puede surgir de un modelo simple o de una explicación posterior. Comprender una fórmula no garantiza que sus supuestos representen el mundo.

SHAP · Método de atribución de contribuciones locales de features. Asigna contribuciones mediante un juego de coaliciones de features. La referencia y el modo de tratar dependencias forman parte de la definición del resultado.

Shapley value · Concepto de teoría de juegos que distribuye un resultado entre participantes según contribución marginal. Promedia el aporte marginal sobre coaliciones con pesos específicos. Para un modelo lineal y juego independiente se reduce a $w_i(x_i - \mu_i)$.

Baseline · Referencia declarada para evaluar pronósticos o para descomponer una salida explicada. En evaluación es un pronóstico de referencia; en SHAP es el valor esperado bajo un juego explicativo. Estos dos usos responden a preguntas distintas.

Expected value · Valor esperado $E[f(x)]$ usado como referencia de la explicación. En 08 es $b + \Sigma w_i \mu_i$, bajo la distribución de referencia definida. Cambiar μ cambia el baseline sin modificar la función f .

Local explanation · Explicación de una predicción concreta. Depende de la observación x y de la referencia. No puede generalizarse automáticamente a todas las observaciones.

Feature contribution · Aporte de una feature al desplazamiento desde baseline hasta output. Se expresa en las mismas unidades que la salida explicada. Aquí su suma reconstruye el desplazamiento respecto de baseline.

Positive contribution · Contribución que aumenta el output respecto del baseline. El signo depende de w y de $x - \mu$, no sólo del valor de la feature. Una misma feature puede cambiar de signo al cambiar la referencia.

Negative contribution · Contribución que reduce el output respecto del baseline. Reduce la salida relativa al baseline elegido. No significa que la feature sea mala ni que intervenirla cause un beneficio.

Linear additive model · Modelo cuya salida es suma de un intercepto y términos lineales de las features. $f(x) = b + \Sigma w_i x_i$ no incluye interacciones entre features. Con coeficientes fijos se puede verificar la suma exactamente.

Model output · Salida numérica producida por el modelo para una observación. Aquí es una magnitud adimensional y puede ser negativa. No se etiqueta como retorno, porcentaje de éxito o probabilidad.

Weight · Coeficiente w_i asociado a una feature. Describe sensibilidad del modelo lineal por unidad de entrada. No equivale a una contribución local sin considerar x y la referencia μ .

Expected feature value · Referencia $E[x_i]$ utilizada en la forma lineal pedagógica. Es μ_i de la distribución de fondo elegida. En 08 el slider cambia todas esas medias simultáneamente.

Causalidad · Relación por la cual intervenir una variable produce un cambio en otra; SHAP no la demuestra. Necesita un diseño o supuestos de identificación adecuados. Una atribución SHAP explica la función predictiva y no identifica ese efecto.

Correlación · Asociación estadística entre variables que no implica causalidad. Las dependencias pueden cambiar el reparto de SHAP condicional. La fórmula independiente del laboratorio no modela esa redistribución.

Aditividad · Propiedad por la cual el output puede descomponerse como baseline más suma de contribuciones. En 08 se comprueba $f(x) = \text{baseline} + \sum \phi$ con un residuo numérico. La propiedad no convierte un modelo complejo en un mecanismo causal.

APÉNDICE · CONSULTA TRANSVERSAL

Vocabulario general

Se conservan y desarrollan todos los términos del apéndice original. Los vocabularios de cada laboratorio incorporan además contexto, fórmulas y límites de interpretación.

Activo · Instrumento o red analizada; en los simuladores se utilizan BTC y ETH como casos pedagógicos. Los nombres BTC y ETH identifican escenarios sintéticos diferentes. Sus trayectorias y métricas no son estimaciones del comportamiento histórico real.

Aditividad · Propiedad por la cual el output puede descomponerse como baseline más suma de contribuciones. En 08 se comprueba $f(x) = \text{baseline} + \sum \phi$ con un residuo numérico. La propiedad no convierte un modelo complejo en un mecanismo causal.

Attention · Mecanismo que asigna pesos relativos a distintas fuentes de información. Pondera fuentes antes de agregarlas. Un peso de atención no es automáticamente una explicación causal ni una medida de importancia global.

Baseline · Referencia declarada para evaluar pronósticos o para descomponer una salida explicada. En evaluación es un pronóstico de referencia; en SHAP es el valor esperado bajo un juego explicativo. Estos dos usos responden a preguntas distintas.

Betweenness · Centralidad basada en la intermediación de un nodo en caminos cortos. Suma fracciones de caminos mínimos entre pares que pasan por el nodo. Aquí es dirigida, no ponderada y normalizada por $(n-1)(n-2)$.

Cell state · Memoria interna de una LSTM. Acumula candidato y memoria previa mediante compuertas. En el integrador es un escalar para facilitar el cálculo; una LSTM real puede usar un vector grande.

Centralidad · Medida de posición o importancia estructural en un grafo. Cada medida responde a una definición de posición estructural. Ninguna demuestra por sí sola identidad, riesgo, fraude o influencia económica.

Data leakage · Uso indebido de información que no estaría disponible al predecir. Puede entrar por features, escaladores, etiquetas, selección o estructura del grafo. Un split cronológico no elimina automáticamente todas estas fuentes.

Directional Accuracy · Proporción de signos correctamente anticipados. Compara $\text{sign}(\hat{y})$ con $\text{sign}(y)$. Un pronóstico de retorno cero no expresa una dirección; en la arena esa métrica se omite para el baseline cash.

Dropout · Regularización que desactiva unidades durante entrenamiento. Durante entrenamiento aplica máscaras aleatorias y reescala activaciones según su implementación. PyTorch lo aplica entre capas recurrentes; el laboratorio 04 sólo modifica curvas sintéticas.

Embedding · Representación vectorial de un nodo, grafo o estado. Es un vector dependiente del encoder y sus parámetros. Una coordenada mayor no significa mayor riesgo ni mejor precisión por sí sola.

Epoch · Una pasada completa por el conjunto de entrenamiento. No equivale a un batch ni a una actualización de parámetros. Aquí el eje de épocas es ilustrativo y no ejecuta optimización.

Feature · Variable de entrada. Una entrada válida debe estar disponible al decidir. En el laboratorio 01 cada paso aporta dos features: precio y retorno logarítmico.

Feature on-chain · Variable derivada de datos de la blockchain. Su construcción requiere fijar red, ventana, confirmaciones y fuente. Un agregado reconstruido posteriormente puede introducir información no disponible al corte.

GAT · Graph Attention Network con atención entre vecinos. Una cabeza calcula scores $\text{LeakyReLU}(a^T[Wh_v || Wh_u])$ y softmax sobre vecinos más self. La atención depende de features y parámetros fijos aquí.

GCN · Graph Convolutional Network con agregación normalizada. Usa $H_{\text{nuevo}} = \text{ReLU}[\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H W]$. Sus coeficientes simétricos no necesariamente suman 1 y no equivalen a un simple promedio por fila.

Generalization · Capacidad de un modelo para funcionar sobre datos no vistos. Debe medirse en períodos no usados para ajuste o selección. Las simulaciones de arquitectura con pesos fijos no evalúan esa capacidad.

GNN · Graph Neural Network: familia de redes para datos con estructura de grafo. Una red que actualiza representaciones a partir de features y relaciones. En 06 sus pesos son fijos; las representaciones se calculan sin entrenamiento.

GraphSAGE · Arquitectura GNN basada en agregación de vecinos. La variante mean concatena $[h_{\text{propio}} || \text{mean}(\text{vecinos})]$ y proyecta con W_S . Este laboratorio usa todos los vecinos y omite normalización L2 posterior.

GRU · Red recurrente Gated Recurrent Unit con estado oculto y dos compuertas. Una red recurrente que utiliza compuertas de actualización y reset sin una celda c separada. Aquí $h = (1-z)g + zh_{\text{anterior}}$; un z alto conserva más estado anterior.

Hidden state · Estado recurrente que resume información previa. Resume el prefijo procesado y alimenta el siguiente paso. No debe confundirse con una predicción final o una etiqueta.

Horizonte · Distancia entre instante de información y target futuro. Aquí H cuenta períodos diarios sintéticos. Cambiar H modifica etiqueta, disponibilidad, solapamiento y frecuencia de decisiones económicas.

Lag · Valor rezagado de una variable. $r(t-1)$ es el retorno del período anterior. El retardo debe calcularse sin desplazar una observación futura hacia una fila anterior.

LSTM · Red recurrente Long Short-Term Memory con memoria explícita. Una red recurrente con estado de celda c y estado oculto h, controlados por compuertas de entrada, olvido y salida. Su utilidad debe contrastarse con baselines bajo el mismo protocolo.

MAE · Error absoluto medio. Se calcula como $\text{media}[|\hat{y} - y|]$ y conserva las unidades de y. Permite interpretar un error típico sin elevar al cuadrado los desvíos.

Max Drawdown · Mayor caída desde un máximo a un mínimo posterior. Se calcula como el máximo de $1 - \text{riqueza} / \text{máximo previo}$. Depende de la secuencia de retornos netos, no sólo de su promedio.

Message passing · Intercambio y agregación de información entre nodos vecinos. Cada capa combina mensajes del estado de la capa anterior. Las actualizaciones son simultáneas; no se usan vecinos parcialmente actualizados en la misma ronda.

Nodo · Unidad de un grafo. En el laboratorio 05 representa una dirección sintética. En otros diseños puede representar una transacción o un contrato; esa decisión cambia la tarea.

Out-of-sample · Datos no utilizados para ajustar el modelo. Excluir datos del ajuste es necesario, pero también hay que excluirlos de la selección. La expresión no garantiza que las features estén libres de fuga.

Overfitting · Ajuste excesivo a Train con peor generalización. Puede afectar pesos, hiperparámetros o selección de estrategias. Una curva ilustrativa ayuda a reconocer el patrón, pero no diagnostica un modelo real.

PageRank · Centralidad que pondera la calidad de los vínculos entrantes. Distribuye masa por enlaces salientes con damping 0,85 y redistribución de nodos sin salida. El modo ponderado usa proporciones de conteos de transacciones.

R² · Métrica de ajuste relativa a una referencia basada en la media. Se calcula como $1 - \text{SSE}/\text{SST}$. Puede ser negativo fuera de muestra; no mide rentabilidad y es indefinido si el target no tiene variación.

Regularización · Técnicas destinadas a controlar complejidad y sobreajuste. Puede incluir penalización de pesos, dropout o parada temprana. Su elección debe hacerse sin consultar el test final.

Retorno · Variación relativa de un activo entre períodos. El retorno simple es $P(t)/P(t-1)-1$; el logarítmico es $\ln[P(t)/P(t-1)]$. Los log-retornos se suman en el horizonte y se convierten con $\exp(r)-1$ para el cálculo económico.

RMSE · Raíz del error cuadrático medio. Se calcula como $\sqrt{\text{media}[(\hat{y}-y)^2]}$ y conserva las unidades de y. Penaliza más los errores grandes; aquí los retornos se informan en puntos porcentuales.

SHAP · Método de atribución de contribuciones locales de features. Asigna contribuciones mediante un juego de coaliciones de features. La referencia y el modo de tratar dependencias forman parte de la definición del resultado.

Sharpe Ratio · Relación entre retorno excedente y volatilidad. En la arena se estima $\text{media}(\text{retorno neto})/\text{desviación muestral} \times \sqrt{(365/H)}$, con tasa libre cero. Esa anualización presupone una escala temporal y no prueba estabilidad de la estrategia.

Snapshot · Estado de un grafo en un tiempo dado. Tiene una ventana de agregación y un tiempo de disponibilidad. En 07 se muestran cinco grafos sintéticos consecutivos.

Softmax · Función que convierte scores en pesos positivos normalizados. $\text{Exp}(a_i)/\sum \text{Exp}(a_j)$ convierte scores en pesos que suman 1. Para estabilidad numérica se resta el máximo de los scores antes de exponenciar.

Split temporal · Separación de datos que preserva orden cronológico. Se asignan muestras por fecha de etiqueta o por una regla documentada de origen. Las ventanas test pueden utilizar historia anterior que ya era conocida.

Target · Variable a predecir. Define la tarea y sus unidades. Cambiar de precio a retorno cambia el significado del error, aunque se conserve la misma ventana de entrada.

Test · Datos reservados para evaluación final. Debe representar datos posteriores no usados en selección. Consultarlo repetidamente para elegir el modelo deja de ser una evaluación final independiente.

Train · Datos usados para ajustar el modelo. Sus datos ajustan pesos y transformaciones como el escalador. Agregar información posterior al corte crea fuga incluso cuando no se modifican las etiquetas.

Validation · Datos usados para selección y vigilancia de generalización. Sirve para comparar configuraciones y seleccionar checkpoints. Repetir la selección sobre el mismo conjunto puede sobreajustar la decisión del investigador.

Ventana temporal · Secuencia fija de observaciones pasadas usada como entrada. Con $L=30$ y $d=2$, una muestra tiene forma 30×2 . Una ventana aporta contexto; no determina por sí sola que una red vaya a aprender mejor.

Walk-forward · Validación que avanza cronológicamente con múltiples cortes. Cada avance agrega pasado conocido y evalúa un período posterior. En 02 se emplean cuatro folds con test de 35 orígenes.

Wallet · Software o dispositivo para gestionar claves y direcciones de una blockchain. Es una herramienta para gestionar claves y direcciones, no una identidad verificada. El laboratorio utiliza direcciones sintéticas como nodos y no agrupa usuarios.

Cierre y evaluación docente

Una actividad realizada no equivale a una respuesta correcta. Evaluá si el alumno reconstruye el cálculo, controla la comparación y reconoce el alcance del resultado.

Criterio	Evidencia observable
Preparación y causalidad	Reconoce forma de X, fecha de etiqueta, purga y disponibilidad.
Cálculo y unidades	Reconstruye una métrica o una traza y conserva sus unidades.
Comparación controlada	Mantiene configuraciones comunes y diferencia costo de error predictivo.
Interpretación crítica	Distingue arquitectura, entrenamiento, atribución y causalidad.
Reproducibilidad	Entrega dos registros, una tabla de comparación y una conclusión con límites.

Transferencia al proyecto real

Documentar datos de Bitcoin o Ethereum, timestamps y disponibilidad, unidad de análisis y etiquetas; ajustar modelos en train; aplicar validación temporal y evaluar mejora incremental con ablaciones. La arena sintética y los pesos fijos preparan estas decisiones y no sustituyen ese experimento.

Fuentes y trazabilidad

[scikit-learn · TimeSeriesSplit](#)

[scikit-learn · Common pitfalls](#)

[PyTorch · LSTM](#)

[PyTorch · GRU](#)

[NetworkX · PageRank](#)

[NetworkX · Betweenness](#)

[Kipf y Welling · GCN](#)

[Hamilton et al. · GraphSAGE](#)

[Veličković et al. · GAT](#)

[SHAP · LinearExplainer](#)

[Lundberg y Lee · SHAP](#)

Trazabilidad de esta revisión

Basada en los ocho HTML y la guía PDF aportados por el profesor. Se corrigieron normalización GCN, concatenación GraphSAGE, atención GAT, convención GRU, conteos de bias, SHAP de referencia y métricas de la arena. Se conservaron los conceptos y los términos docentes, con explicaciones desarrolladas.